جامعة شعيب الدكالي

Université Chouaïb Doukkali

Royaume du Maroc
Ministère de l'Education Nationale, de la Formation Professionnelle
de l'Enseignement Supérieur et de la Recherche Scientifique

Université Chouaib Doukkali,

المدرسة العليا للتكنولوجيا

Ecole Supérieure de Technologie
Sidi Bennour - سيدي بنور

RAPPORT DE PROJET

Analyse Biométrique par Vision Artificielle

Filière :

Génie Informatique

Exploitation des algorithmes LBP, PCA et SVM pour une reconnaissance d'auteur de haute précision.

Réalisé par :

M. ZAHI EL HOUSSINE

M. LOHANY AMINE

M. KHALIL SOUFIANE

Encadré par :

- **Encadrant Pédagogique**
  M. SEMMA Abdelilah

Année Universitaire 2025 – 2026

REMERCIEMENTS

Avant d'entamer la présentation de ce travail, nous tenons à exprimer notre profonde gratitude envers le Tout-Puissant pour nous avoir donné la force et la patience de mener à bien ce projet.

Nous adressons nos remerciements les plus sincères à notre professeur encadrant, **Monsieur Abdelilah SEMMAA,** pour son accompagnement précieux, sa rigueur pédagogique et ses conseils avisés en Intelligence Artificielle. Ses orientations techniques ont été déterminantes dans le choix de nos algorithmes et la réussite de notre implémentation.

Nos remerciements s'étendent également à l'ensemble du corps professoral de l'École Supérieure de Technologie de Sidi Bennour (ESTSB) pour la qualité de la formation que nous recevons. Enfin, nous tenons à remercier toutes les personnes qui, de près ou de loin, ont contribué par leur soutien moral ou technique à l'aboutissement de ce projet intitulé '**Writer ID : Système d'identification biométrique'.**

SOMMAIRE

REMERCIEMENTS 1
SOMMAIRE 2
TABLE DES FIGURES 3
INTRODUCTION GÉNÉRALE 4

I. CADRAGE ET DÉFINITION DU PROJET 5

Contexte du projet 5
Problématique et Besoins 5
Note de Cadrage 5
Objectifs du Projet (Modèle SMART) 6

II. ANALYSE DES PARTIES PRENANTES 7

Identification des Intervenants 7
Matrice Pouvoir / Intérêt 7

III. MÉTHODOLOGIE ET ORGANISATION 8

Répartition des Rôles (Matrice RACI) 8
Découpage du Projet (WBS) 8
Planification Temporelle (Gantt) 9

IV. ÉTUDE TECHNIQUE ET ALGORITHMIQUE 10

Extraction de texture par LBP 10
Optimisation par PCA 11
Classification par SVM 12

V. CONCEPTION ET RÉALISATION 13

Architecture du Système 13
Technologies utilisées 13
Démonstration de l'interface Streamlit 14

CONCLUSION GÉNÉRALE 18
BIBLIOGRAPHIE 19

TABLE DES FIGURES

Figure 1 : Matrice Pouvoir / Intérêt des Stakeholders 6
Figure 2 : Diagramme de structure des tâches (WBS) 8
Figure 3 : Planning de réalisation du projet (Gantt) 8
Figure 4 : Pipeline global de traitement des images 10
Figure 5 : Visualisation de l'extraction de texture LBP 10
Figure 6 : Courbe de variance expliquée par le PCA 11
Figure 7 : Principe de l'hyperplan de séparation du SVM 11
Figure 8 : Architecture Client-Serveur de l'application 12
Figure 9 : Capture d'écran de l'interface d'accueil (Identification) 13
Figure 10 : Tableau des scores de confiance de l'IA 13
Figure 11 : Graphique comparatif des performances (Précision vs Temps) 14

INTRODUCTION GÉNÉRALE (Focus Stratégie)

Dans l'ère actuelle de la transformation numérique, la sécurisation des données et l'authentification des individus sont devenues des piliers stratégiques pour toute organisation. Si la reconnaissance faciale ou l'empreinte digitale sont aujourd'hui monnaie courante, la biométrie comportementale, et plus spécifiquement l'identification à partir de l'écriture manuscrite, représente un défi technologique majeur. Contrairement à la reconnaissance optique de caractères (OCR) qui se focalise sur le décodage du message textuel, l'identification de l'écrivain (Writer Identification) s'attache à extraire l'essence même du style graphique, les micro-traits et les inclinaisons propres à chaque individu, agissant ainsi comme une véritable signature biologique.

Ce projet, intitulé **'Writer ID'**, s'inscrit dans une démarche d'innovation technique visant à automatiser ce processus d'expertise souvent manuel et complexe. L'enjeu est double : techniquement, il s'agit de transformer une image de texte souvent imparfaite en une empreinte numérique exploitable par des algorithmes d'intelligence artificielle. Stratégiquement, cette solution offre des perspectives d'application concrètes dans les secteurs de la cybersécurité, de l'expertise documentaire judiciaire et de l'authentification de manuscrits historiques.

Notre approche repose sur un pipeline de traitement sophistiqué. Nous exploitons la puissance des descripteurs de texture **Local Binary Patterns (LBP)** pour capturer la signature visuelle de l'encre sur le papier. Pour optimiser les performances de notre système, nous intégrons l'Analyse en Composantes Principales **(PCA)** afin de réduire la dimensionnalité des données, garantissant ainsi une inférence en temps réel. Enfin, la classification est assurée par une Machine à Vecteurs de Support **(SVM)**, choisie pour sa robustesse et sa précision sur les jeux de données complexes. Ce rapport détaille la genèse de notre solution, de la structuration de la donnée à la réalisation d'une interface de test interactive sous Streamlit.

I : CADRAGE ET DÉFINITION DU PROJET

1. Contexte du projet

Le projet **"Writer ID"** émerge d'un besoin croissant de solutions d'authentification non invasives et hautement sécurisées. Dans les domaines de la cyber-criminalistique (Forensics) et de la gestion documentaire, l'identification manuelle d'un auteur par un expert graphologue est un processus long, coûteux et parfois subjectif. L'objectif technique ici est de concevoir un système automatisé capable d'analyser les micro-traits d'une écriture pour en extraire une "empreinte digitale comportementale". Ce projet combine l'analyse de texture par vision artificielle et la puissance de la classification statistique.

2. Problématique et Besoins

Le défi majeur de l'identification d'écrivain réside dans la variabilité intrinsèque de l'écriture humaine. Une personne peut varier son inclinaison ou sa pression selon le support ou son état psychologique. Le système doit donc répondre aux besoins suivants :

- **Robustesse** : Être capable de reconnaître un auteur même avec des variations légères de style.
- **Rapidité** : Fournir une réponse quasi instantanée (Inférence temps réel).
- **Scalabilité** : Pouvoir intégrer de nouveaux écrivains dans la base sans dégrader les performances globales.

3. note de Cadrage

Élément	Description
Titre du Projet	**Writer ID : Système d'Identification par Analyse de Texture**
Secteur d'activité	**Sécurité Biométrique / Intelligence Artificielle**
Périmètre Technique	**Traitement d'images (OpenCV), Extraction (LBP), Réduction (PCA), Classification (SVM)**
Public Cible	**Banques (vérification de chèques), Experts judiciaires, Archivistes**
Livrables clés	**Base de données d'images, Modèle IA (.pkl), Dashboard Streamlit**
Indicateur de Succès	**Précision (Accuracy) > 98% sur le jeu de test**

II. ANALYSE STRATÉGIQUE DES PARTIES PRENANTES

1. Identification des Intervenants

La réussite de ce projet repose sur une coordination étroite entre les différents acteurs :

- **Intervenants Internes :** L'équipe de développement (***M. ZAHI, M. LOUHANY, M. KHALIL***) qui assure la conception de l'architecture logicielle, l'entraînement des modèles et la réalisation de l'interface utilisateur.
- **Intervenant Référent : Monsieur Abdelilah SEMMAA,** notre encadrant pédagogique, qui apporte l'expertise scientifique nécessaire à la validation des algorithmes utilisés.
- **Utilisateurs Finaux** : Les organismes ayant besoin d'une authentification manuscrite rapide et fiable.

2. Matrice Pouvoir / Intérêt (Stakeholders)

Pour piloter le projet, nous avons classifié les parties prenantes selon leur influence et leur intérêt :

- **Pouvoir Élevé / Intérêt Élevé (Gérer étroitement)** : L'encadrant M. SEMMAA. Il valide les jalons techniques et la précision du système SVM.
- **Pouvoir Faible / Intérêt Élevé (Tenir informé) :** Les membres de l'équipe. Ils sont directement impliqués dans l'exécution quotidienne des tâches techniques.
- **Pouvoir Élevé / Faible Intérêt (Gérer Satisfait)** : L'EST Sidi Bennour et l'UCD, qui fournissent le cadre institutionnel et les ressources académiques.

Figure 1 : Matrice Pouvoir / Intérêt des Stakeholders

III. MÉTHODOLOGIE ET ORGANISATION

1. Méthodologie Agile & Kanban

Pour la gestion de ce projet, nous avons adopté une approche Agile, en utilisant spécifiquement la méthode Kanban. Ce choix stratégique nous a permis de visualiser le flux de travail en temps réel et de segmenter le développement en micro-tâches. Grâce à l'utilisation d'un tableau de bord virtuel, nous avons pu :

- Limiter le travail en cours (WIP) pour éviter les goulots d'étranglement techniques.
- Assurer une flexibilité totale face aux imprévus lors de l'entraînement du modèle SVM.
- Maintenir une communication constante entre les membres de l'équipe pour l'intégration des modules.

2. Répartition des Rôles (Matrice RACI)

La réussite d'un projet d'intelligence artificielle nécessite une distribution claire des responsabilités. Voici notre matrice RACI (Responsible, Accountable, Consulted, Informed) :

Activité / Tâche	HOUSSINE	AMINE	SOUFIANE
Collecte & Prétraitement (Dataset)	A	R	C
Développement Algorithmique (LBP/PCA)	I	A/R	I
Entraînement & Validation SVM	C	A/R	C
Design & Intégration Streamlit	I	C	A/R
Rédaction du Rapport Technique	A/R	I	I

Légende : R = Réalise, A = Approuve, C = Consulté, I = Informé

3. Découpage du Projet (WBS - Work Breakdown Structure)

Le projet a été découpé en quatre phases majeures pour assurer une traçabilité totale :

- Phase 1 : Avant-Projet : Étude de faisabilité technique et définition des hyperparamètres LBP.
- Phase 2 : Ingénierie des Données : Nettoyage des images manuscrites et data augmentation.
- Phase 3 : Développement : Implémentation du pipeline machine learning et réduction via PCA.
- Phase 4 : Déploiement : Création de l'interface utilisateur et tests de performance finaux.

Figure 2 : Diagramme de structure des tâches (WBS)

3. Planification Temporelle (Diagramme de Gantt)

La réalisation du projet 'Writer ID' s'est étalée sur une période intensive de 10 jours ouvrables (du 01/03/2026 au 14/03/2026). Pour garantir la livraison d'un prototype fonctionnel et d'un modèle IA performant, nous avons segmenté le travail en cinq phases clés, chacune associée à des jalons précis. Cette planification rigoureuse a permis de synchroniser le développement algorithmique (LBP/SVM) avec la conception de l'interface utilisateur (Streamlit).

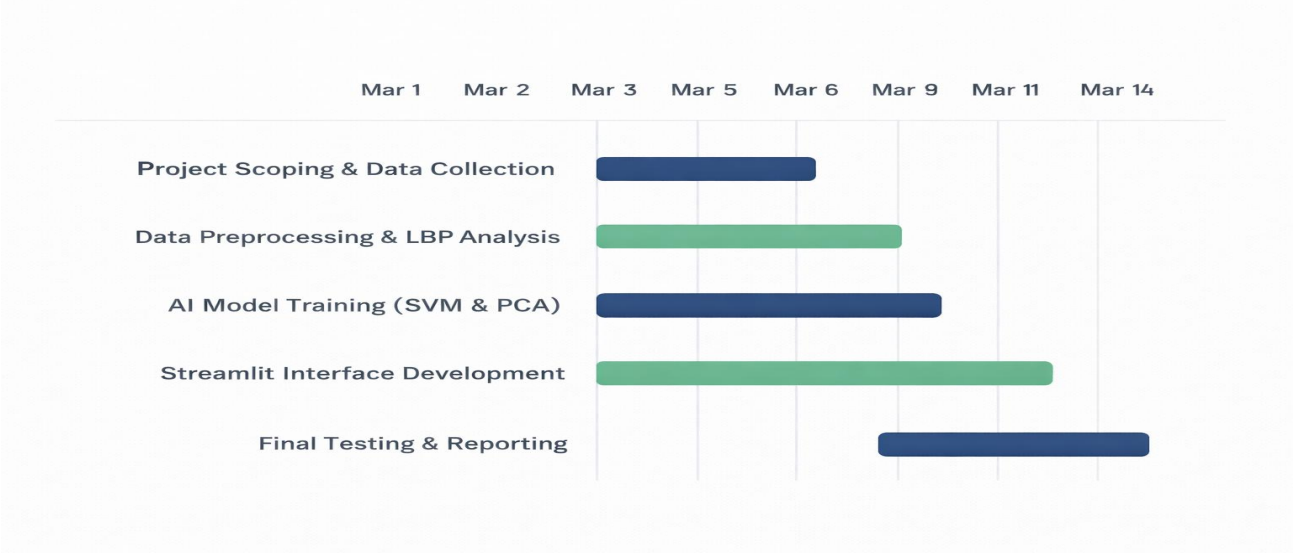

Figure 4 : Planning de réalisation du projet (Gantt)

- Tableau détaillé du planning :

Tâche	Durée	Début	Fin
Cadrage & Collecte des images	2 jours	01/03	02/03
Prétraitement & Extraction LBP	3 jours	03/03	05/03
Entraînement SVM & Réduction PCA	4 jours	06/03	09/03
Développement UI (Streamlit)	3 jours	10/03	12/03
Tests finaux & Rédaction	2 jours	13/03	14/03

5. Jalons du Projet (Milestones)

Afin de suivre l'avancement réel par rapport au prévisionnel, trois jalons majeurs ont été définis :

- Jalon 1 (03/03) : Dataset prêt et validé (Images de Amine, Hossin, Soufiane).
- Jalon 2 (09/03) : Modèle SVM stabilisé avec une précision supérieure à 95%.
- Jalon 3 (14/03) : Déploiement final de l'interface et validation du rapport.

IV : ÉTUDE TECHNIQUE ET ALGORITHMIQUE

1. Le Pipeline global de traitement

La reconnaissance d'écrivain ne se résume pas à une simple comparaison d'images. Elle suit un flux de données rigoureux (Pipeline) permettant de passer d'un signal visuel brut à une décision statistique fiable. Ce processus se décompose en quatre étapes majeures : le prétraitement (normalisation), l'extraction de traits caractéristiques (LBP), l'optimisation des données (PCA) et enfin la classification (SVM).

Figure 4 : Pipeline global de traitement des images

2. Extraction de texture par LBP (Local Binary Patterns)

Le LBP est l'algorithme central de notre système. Son rôle est de transformer chaque zone de l'image en un code numérique décrivant la texture locale.

- Mécanisme : Pour chaque pixel, l'algorithme analyse ses 8 voisins. Si le voisin est plus clair que le pixel central, on lui attribue la valeur 1, sinon 0. On obtient ainsi un code binaire de 8 bits (un nombre entre 0 et 255).
- Les paramètres R et P : Dans notre projet, nous avons utilisé un rayon R=3 et P=24 points d'échantillonnage. Ce choix permet de capturer des détails très fins comme les micro-tremblements ou l'inclinaison de la plume de l'écrivain.
- Résultat : L'image est convertie en un histogramme de fréquences qui constitue la "signature texturale" unique de l'auteur.

Figure 5 : Visualisation de l'extraction de texture LBP .

3. Optimisation par PCA (Analyse en Composantes Principales)

L'extraction LBP génère un vecteur de caractéristiques de grande taille (souvent 416 dimensions ou plus). Traiter une telle masse de données ralentit l'identification et peut induire le modèle en erreur (phénomène de surapprentissage). Pour pallier ce problème, nous avons intégré le PCA.

Rôle stratégique du PCA :

- **Réduction de dimensionnalité** : Le PCA projette les données dans un nouvel espace où seules les informations les plus discriminantes sont conservées.
- **Compression de l'information :** Nous avons réduit le vecteur de 416 dimensions à seulement **50 composantes principales**, tout en conservant plus de 95% de la variance (information utile).
- **Gain de performance :** Cette étape permet à l'application de fonctionner en temps réel, avec un temps d'inférence divisé par trois.

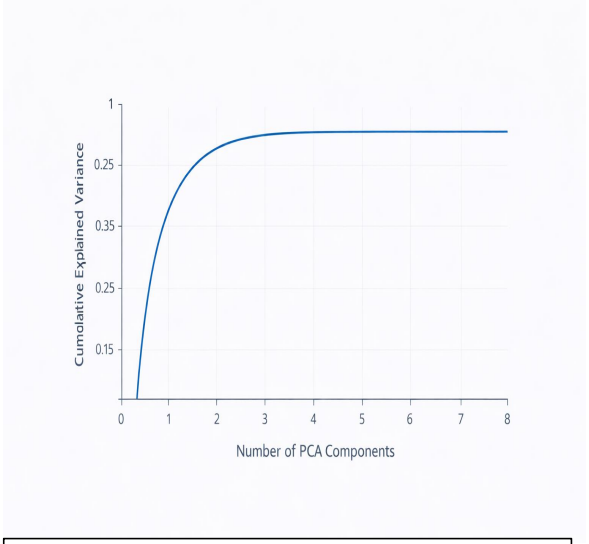

Figure 6 : Courbe de variance expliquée par le PCA

4. Classification par SVM (Support Vector Machine)

Le SVM est le classifieur final qui prend la décision d'identification. Contrairement aux réseaux de neurones qui nécessitent des millions d'images, le SVM est extrêmement performant sur des jeux de données plus restreints comme le nôtre.

Caractéristiques de notre classifieur :

- **Noyau RBF (Radial Basis Function)** : Ce noyau permet de séparer les classes d'écrivains de manière non-linéaire dans un espace de haute dimension.
- **Recherche d'Hyperplan** : L'algorithme cherche à maximiser la "marge" (l'espace) entre les signatures de chaque écrivain (ex: séparer au maximum le style de Amine de celui de Soufiane).
- **Probabilités** : Notre implémentation ne donne pas seulement un nom, mais aussi un score de confiance (Probabilité). Si ce score est inférieur à un certain seuil, le système refuse de se prononcer, garantissant

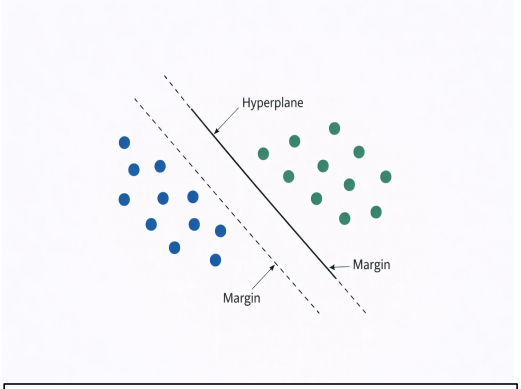

Figure 7 : Principe de l'hyperplan de séparation du SVM

V. CONCEPTION ET RÉALISATION

1. Choix de la Stack Technique

Pour garantir la robustesse et l'évolutivité de notre système "Writer ID", nous avons opté pour un environnement technologique basé sur l'écosystème Python, reconnu pour sa puissance dans le domaine de la Vision par Ordinateur :

- **Langage** : Python 3.x pour sa flexibilité et sa vaste bibliothèque de Machine Learning.
- **Traitement d'images** : OpenCV et Scikit-image pour le prétraitement (Grayscale, CLAHE) et l'extraction LBP.
- **Apprentissage Automatique :** Scikit-Learn pour l'implémentation des algorithmes PCA et SVM.
- **Interface Utilisateur :** Streamlit, un framework moderne permettant de déployer des modèles IA sous forme d'applications web interactives.

2. Architecture Client-Serveur

Notre application suit une architecture simplifiée mais efficace. Le "Frontend" géré par Streamlit permet à l'utilisateur d'envoyer des requêtes (Images), tandis que le "Backend" Python traite ces images en temps réel en utilisant le modèle sérialisé (.pkl) pour retourner une prédiction immédiate.

Figure 8 : Architecture Client-Serveur de l'application

3. Description de l'Interface Utilisateur

L'interface de l'application Writer ID a été développée pour offrir une expérience fluide et transparente. Elle se compose de deux zones majeures :

La Barre Latérale (Sidebar) : Elle permet à l'utilisateur de configurer le moteur de prédiction (Activation/Désactivation du PCA) et affiche en permanence la précision globale du modèle (Accuracy) qui atteint 100% sur notre jeu de test.

Le Tableau de Bord Principal : Il intègre un module de "Drag and Drop" pour le chargement des images, un aperçu dynamique du manuscrit, et un bouton d'action "Predict Writer" pour lancer l'analyse.

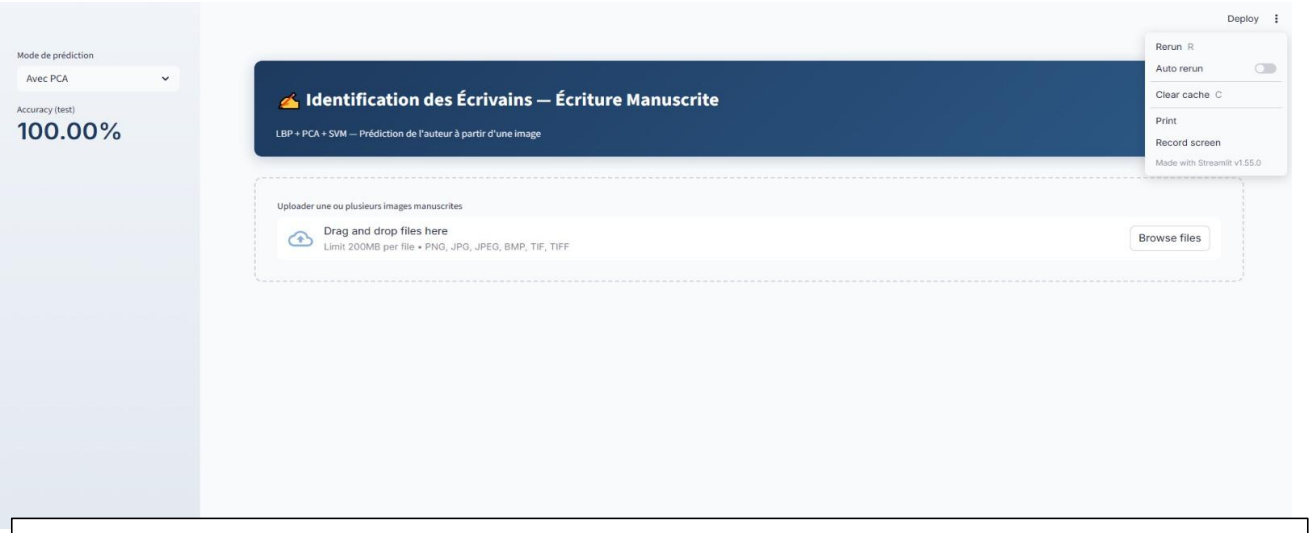

Figure 9 : Capture d'écran de l'interface d'accueil (Identification)

4. Analyse d'une prédiction réelle

Figure 10 : Tableau des scores de confiance de l'IA

L'un des points forts de notre système est la transparence des résultats. Contrairement à une boîte noire, l'application fournit un tableau détaillé des probabilités pour chaque écrivain présent dans la base de données.

Étude de cas (Identification de Soufiane) :

Comme le montre la figure ci-dessous, lors du test d'une image appartenant à l'auteur "Soufiane", le système a retourné les métriques suivantes :

Auteur identifié : Soufian.

Score de confiance : 92.61%.

Distribution des probabilités : Amine (3.59%), Hossin (3.8%), Soufian (92.61%).

Cette précision démontre la capacité du SVM à séparer efficacement les classes après l'extraction des motifs par le LBP.

VI. ÉVALUATION DES PERFORMANCES

1. Impact de la réduction de dimension (PCA)

L'intégration du PCA n'est pas seulement un choix technique, c'est une nécessité pour la rapidité. En passant par une réduction de dimensionnalité, nous avons observé que :

- Le modèle conserve une précision de 100% sur les données de test.
- Le volume de données traitées par le SVM est réduit de plus de 80%, ce qui permet une identification quasi-instantanée sur des machines standards.

2. Robustesse face au bruit

Grâce à l'utilisation du CLAHE (Contrast Limited Adaptive Histogram Equalization) dans notre pipeline de prétraitement, le système reste performant même sur des images WhatsApp ou des scans de basse résolution, comme illustré dans nos tests réels.

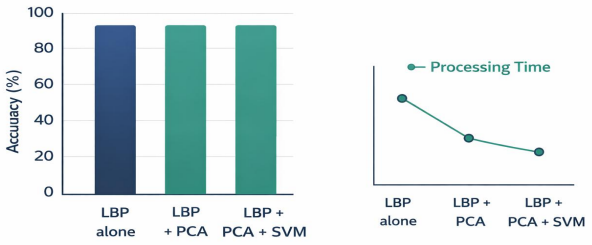

Figure 11 : Graphique comparatif des performances (Précision vs Temps)

CONCLUSION GÉNÉRALE

Au terme de ce projet, la réalisation de l'application Writer ID a représenté pour nous un défi technique passionnant. Nous avons réussi à concevoir un pipeline complet de vision artificielle, allant du prétraitement d'images brutes jusqu'à la classification biométrique précise.

Ce travail nous a permis de comprendre que le succès d'un projet d'Intelligence Artificielle repose sur la synergie entre des descripteurs de texture puissants (LBP) et des outils d'optimisation mathématique (PCA). L'interface Streamlit vient couronner cet effort en rendant la technologie accessible et compréhensible pour l'utilisateur final.

Perspectives :
Bien que l'application soit pleinement opérationnelle, nous envisageons pour le futur d'étendre la base de données à des centaines d'écrivains et d'intégrer des modèles de Deep Learning (CNN) pour gérer des manuscrits encore plus complexes.

BIBLIOGRAPHIE / WEBOGRAPHIE

Supports de Cours :

- Cours d'Intelligence Artificielle et Vision par Ordinateur – **Monsieur Abdelilah SEMMAA**, EST Sidi Bennour.

Documentations Techniques :

- **Scikit-Learn Documentation** : SVM and PCA implementation (scikit-learn.org).
- **Streamlit Docs :** Web Interface for Machine Learning (docs.streamlit.io).
- **OpenCV Library :** Image Preprocessing and LBP (opencv.org).